Universidad Complutense de Madrid
Máster en Data Science, Big Data & Business Analytics



Trabajo de Fin de Máster

Predicción de vulnerabilidad socioeconómica y exclusión financiera en hogares españoles mediante técnicas de Machine Learning

Autora: Lina Maria Caro Perdomo

Curso 2025-2026

17 de septiembre de 2026

Índice

Índice 2
1. Introducción y motivación 4
2. Objetivos 4
3. Fuente de datos y descripción del dataset 5
3.1 Descripción de la Encuesta de Condiciones de Vida (ECV) 5
3.2 Variables seleccionadas para el análisis 5
3.3 Limitaciones y consideraciones del dataset 6
4. Construcción de la variable objetivo 6
4.1 Dimensión de pobreza 6
4.2 Dimensión de exclusión financiera 7
4.3 Definición del índice de vulnerabilidad combinada 7
5. Análisis exploratorio de datos (EDA) 8
5.1 Estadísticas descriptivas 8
5.2 Distribución de variables clave 8
5.3 Análisis de correlaciones 9
5.4 Análisis territorial por Comunidad Autónoma 10
6. Preprocesamiento y transformación de datos 11
6.1 Tratamiento de valores nulos 11
6.2 Codificación de variables categóricas 11
6.3 Normalización de variables numéricas 12
6.4 Gestión del desbalanceo de clases 12
7. Modelización 13
7.1 Regresión Logística 13
7.2 Random Forest 13
7.3 Support Vector Machine (SVM) 13
7.4 Clustering no supervisado con K-Means 14
8. Evaluación y comparación de modelos 14
8.1 Métricas de evaluación 14
8.2 Comparativa de resultados 15
8.3 Selección del modelo óptimo 15
9. Interpretabilidad de resultados 15
9.1 Feature importance (Random Forest) 15
9.2 Coeficientes de la Regresión Logística 16
9.3 Perfiles de vulnerabilidad identificados 17
10. Visualización territorial de resultados 17
11. Productivización del modelo 19
11.1 Desarrollo de la aplicación en Gradio 19

11.2 Demostración funcional 19
11.3 Explicabilidad individual (SHAP) 20
12. Conclusiones 21
12.1 Principales hallazgos 21
12.2 Limitaciones del estudio 22
12.3 Líneas de mejora futura 22
13. Bibliografía 23
Anexos 24
Anexo A: Código completo (Jupyter Notebook) 24
Anexo B: Diccionario de variables utilizadas 24
Anexo C: Resultados detallados de los modelos 25
Anexo D: Gráficos complementarios del análisis exploratorio 26

1. Introducción y motivación

La vulnerabilidad socioeconómica es un fenómeno multidimensional que no se explica únicamente por el nivel de ingresos de un hogar. Dos hogares situados por debajo del umbral de riesgo de pobreza pueden encontrarse en situaciones radicalmente distintas: uno puede mantener sus pagos al día gracias a la ausencia de deudas o a una vivienda en propiedad ya pagada, mientras que otro puede tener retrasos en el pago de la hipoteca, las facturas o los préstamos, agravando su situación de exclusión. Esta segunda dimensión "la exclusión financiera" capta problemas de liquidez y capacidad de pago que no siempre coinciden con estar por debajo del umbral de pobreza monetaria. Combinar ambas dimensiones permite identificar a los hogares en una situación de mayor vulnerabilidad, más allá de lo que revela cualquiera de los dos indicadores por separado.

Este Trabajo de Fin de Máster nace de la intención de analizar esta doble dimensión de forma conjunta, utilizando los microdatos públicos de la Encuesta de Condiciones de Vida (ECV) del Instituto Nacional de Estadística (INE), la cual es publicada anualmente. A partir de estos datos se construye una variable objetivo, definiéndola como el hogar "doblemente vulnerable" que combina el riesgo de pobreza monetaria con la presencia de al menos un indicador de exclusión financiera, y se desarrolla un pipeline analítico completo, desde la exploración de los datos hasta la productivización de un modelo predictivo.

La motivación de este trabajo no es únicamente académica. Identificar con antelación los hogares con mayor riesgo de vulnerabilidad combinada tiene un impacto directo en el diseño de políticas sociales, en la focalización de ayudas públicas y en la evaluación de riesgo por parte de entidades financieras y aseguradoras. Por ello, el trabajo se ha desarrollado con una orientación que no se limita a maximizar métricas de rendimiento, sino que pretende ofrecer una interpretación clara y accionable de los resultados.

2. Objetivos

Objetivo general:

Desarrollar un pipeline analítico completo, reproducible e interpretable para la predicción de la vulnerabilidad socioeconómica y exclusión financiera en los hogares españoles, a partir de los microdatos de la ECV.

Objetivos específicos:

-Construir una variable objetivo que combine indicadores de riesgo de pobreza y de exclusión financiera, justificando metodológicamente su definición.

-Realizar un análisis exploratorio de datos completo, identificando la distribución, correlación y diferencias territoriales asociadas a la vulnerabilidad.

-Diseñar un pipeline de preprocesamiento reproducible que trate adecuadamente los valores nulos, las variables categóricas y el desbalanceo de clases.

-Comparar distintas técnicas de clasificación supervisada (Regresión Logística, Random Forest y Support Vector Machine), optimizando sus hiperparámetros mediante validación cruzada y evitando la inclusión de variables que generen fuga de información hacia la variable objetivo.

-Aplicar una técnica de aprendizaje no supervisado (K-Means) para identificar perfiles socioeconómicos de vulnerabilidad.

-Interpretar los resultados del modelo óptimo de forma accesible para un público no técnico, orientado a la toma de decisiones.

-Productivizar el modelo mediante una aplicación funcional desarrollada con Gradio, capaz de generar predicciones sobre nuevos perfiles de hogares.

3. Fuente de datos y descripción del dataset

3.1 Descripción de la Encuesta de Condiciones de Vida (ECV)

La Encuesta de Condiciones de Vida (ECV) es una operación estadística armonizada a nivel europeo (EU-SILC) que el INE realiza anualmente con el objetivo de analizar la renta, la pobreza, la exclusión social y las condiciones de vida de los hogares españoles (INE, Metodología ECV). Para este trabajo se han utilizado los microdatos del 2025, correspondientes a los ficheros de hogar (H) y de datos básicos de hogar (D), que tras su combinación conforman un dataset de 29.369 hogares.

Se ha optado por trabajar a nivel de hogar y no a nivel de persona, dado que la variable objetivo de este estudio (la vulnerabilidad socioeconómica) es una característica del hogar en su conjunto y no de sus miembros individualmente. Los ficheros de personas (R) y de adultos (P) no se han incorporado al dataset de trabajo por este motivo, si bien se identifican en el apartado de limitaciones como una posible vía de mejora futura del modelo.

3.2 Variables seleccionadas para el análisis

Del conjunto total de variables disponibles en la ECV se ha seleccionado un subconjunto de 22 variables relevantes para el estudio de la vulnerabilidad, agrupadas en las siguientes categorías:

-Identificación y geografía: identificador de hogar, Comunidad Autónoma y grado de urbanización.

-Indicadores de pobreza (calculados por el INE): riesgo de pobreza, carencia material severa y renta disponible del hogar.

-Indicadores de exclusión financiera: retrasos en el pago de hipoteca o alquiler, retrasos en facturas, retrasos en préstamos, capacidad para afrontar gastos imprevistos, capacidad para llegar a fin de mes y carga financiera de las deudas.

-Indicadores de privación material: capacidad de permitirse vacaciones, capacidad de permitirse comida con proteína cada dos días, capacidad de mantener una temperatura adecuada en la vivienda, disponibilidad de ordenador y de vehículo.

-Características de la vivienda y del hogar: tipo de vivienda, régimen de tenencia, número de habitaciones, número de miembros del hogar y tipo de hogar (composición del hogar).

3.3 Limitaciones y consideraciones del dataset

El dataset presenta limitaciones que conviene explicar. En primer lugar, aunque la ECV tiene un diseño de panel (los mismos hogares participan hasta cuatro años seguidos), este trabajo utiliza únicamente los datos de la edición del 2025, es decir, una única foto fija en el tiempo. Esto significa que no podemos saber si un hogar identificado como vulnerable lleva años en esa situación (algo estructural) o si está pasando por un mal momento puntual (algo coyuntural, como perder un empleo temporalmente). Aprovechar varios años de la ECV en el futuro permitiría distinguir entre ambos casos.

En segundo lugar, varias variables presentaban un porcentaje elevado de valores en blanco (no detectados como nulos) que, tras el análisis correspondiente, se determinó que no correspondían a datos faltantes sino a preguntas no aplicables a determinados hogares (por ejemplo, la pregunta sobre retrasos en el pago de la hipoteca no aplica a un hogar sin hipoteca ni alquiler). Este aspecto se desarrolla en detalle en el apartado 6.1.

En tercer lugar, el umbral de riesgo de pobreza que utiliza la ECV es único a nivel nacional (60% de la renta mediana), sin ajustarse al coste de vida de cada zona. Esto significa que ese mismo umbral se aplica igual en un municipio pequeño que en una gran ciudad, aunque el coste de la vivienda y de los suministros pueda ser distinto entre ambos. Esta limitación podría estar afectando en particular a los hogares en alquiler de renta baja identificados en el análisis de clusters (Cluster 2, apartado 9.3), cuya vulnerabilidad podría estar parcialmente influida por el coste de la vivienda en su zona, además del nivel de renta y el régimen de tenencia en sí mismos.

Por último, dos de las comunidades autónomas estudiadas (Ceuta y Melilla) cuentan con un tamaño muestral considerablemente menor que el resto (187 y 209 hogares). Esto implica que sus estimaciones de riesgo, aunque se ubican entre las más altas del análisis territorial (apartado 10), tienen un margen de error mayor y se deben interpretarse con cuidado contemplando esta situación.

4. Construcción de la variable objetivo

La variable objetivo de este trabajo, denominada “hogar doblemente vulnerable”, se ha construido combinando dos dimensiones independientes de vulnerabilidad socioeconómica: el riesgo de pobreza monetaria y la exclusión financiera. La combinación de ambas dimensiones, y no su interpretación de manera individual, es lo que diferencia este trabajo de los indicadores de pobreza convencionales.

4.1 Dimensión de pobreza

La variable de pobreza se extrae de vhPobreza calculada por el INE. Esta variable identifica a los hogares cuya renta disponible equivalente se sitúa por debajo del 60% de la renta mediana nacional. Esta variable se utiliza como condición necesaria, aunque no suficiente, para clasificar a un hogar como doblemente vulnerable.

4.2 Dimensión de exclusión financiera

La dimensión de exclusión financiera se ha construido a partir de cinco indicadores binarios, cada uno de los cuales señala la presencia de una dificultad financiera concreta en el hogar:

- Retrasos en el pago de la hipoteca o el alquiler.
- Retrasos en el pago de facturas de suministros.
- Retrasos en el pago de préstamos o compras a plazos.
- Incapacidad para afrontar un gasto imprevisto.
- Dificultad elevada para llegar a fin de mes.

La sumatoria de estos cinco indicadores es la variable (suma_exclusion), la cual oscila entre 0 y 5, y que cuantifica el número de dificultades financieras que al mismo tiempo experimenta un hogar.

4.3 Definición del índice de vulnerabilidad combinada

Un hogar se clasifica como “doblemente vulnerable” (vulnerable = 1) cuando se encuentra en riesgo de pobreza (vhPobreza = 1) y tiene, además, al menos uno de los cinco indicadores de exclusión financiera activos (suma_exclusion ≥ 1). Esta definición es más valiosa que analizar cada dimensión por separado: la tabla cruzada de pobreza y exclusión financiera del apartado 5.2 muestra que hay hogares en riesgo de pobreza que no tienen problemas de exclusión financiera, y al revés, hogares con exclusión financiera que no están en riesgo de pobreza. Por eso, el hecho de que se cumplan las dos condiciones a la vez permite que el estudio evalúe solo los hogares que están realmente en la situación más frágil.

La aplicación de este índice de vulnerabilidad combinada sobre la muestra del dataset (29.369 hogares) da como resultado 3.415 hogares clasificados como doblemente vulnerables, lo que representa el 11,6% del total. Este porcentaje supone un desbalanceo de clases moderado, que se puede manejar ajustando los pesos en los algoritmos de clasificación, sin necesidad de recurrir a técnicas de sobremuestreo sintético como SMOTE. Esto se explica con más detalle en el apartado 6.4.

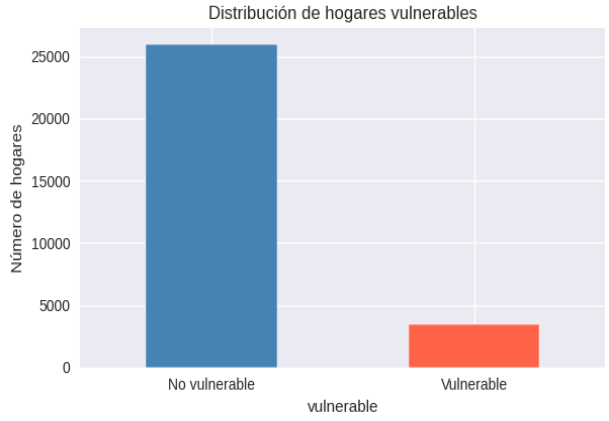


Figura 1: Distribución de hogares vulnerables.

TABLA RESUMEN — POBREZA VS EXCLUSIÓN FINANCIERA

Con exclusión financiera	False	True	All
En riesgo pobreza			
0	16451	7917	24368
1	1586	3415	5001
All	18037	11332	29369

Tabla 1: Tabla cruzada de pobreza Vs exclusión financiera.

5. Análisis exploratorio de datos (EDA)

5.1 Estadísticas descriptivas

VARIABLES CONTINUAS:

	vhRentaa	HH030	HB120
count	29369.00	29369.00	29369.00
mean	39896.35	4.88	2.43
std	27486.61	1.52	1.23
min	-28024.30	1.00	1.00
25%	21033.99	4.00	1.00
50%	34733.50	5.00	2.00
75%	51693.90	6.00	3.00
max	522875.20	10.00	13.00

Tabla 2: Estadísticas descriptivas de las variables continuas.

Las variables continuas muestran una renta disponible media de 39.896,35 € (mediana: 34.733,50 €), con una dispersión considerable (desviación típica de 27.486,61 €) y un rango que va desde valores negativos (posible en la renta disponible de hogares con rentas de capital o actividad económica, y no necesariamente un error de datos) hasta un máximo de 522.875,20 €. Los hogares de la muestra tienen, de media, 4,88 habitaciones y 2,43 miembros.

Variables categóricas:

- vhPobreza: 83,0% hogares no pobres / 17,0% en riesgo de pobreza.
- vhMATDEP: 93,4% sin carencia material severa / 6,6% con carencia.
- vulnerable (target): 88,4% no vulnerables / 11,6% vulnerables.
- HS120 (fin de mes): 30,8% con cierta facilidad · 23,5% con cierta dificultad · 22,5% con facilidad · 11,3% con dificultad · 7,7% con mucha dificultad · 4,1% con mucha facilidad.
- HS060 (gastos imprevistos): 67,0% puede afrontarlos / 33,0% no puede.
- HH021 (régimen de tenencia): 51,9% propiedad sin hipoteca · 26,1% propiedad con hipoteca · 12,7% alquiler a precio de mercado · 6,2% cesión gratuita · 3,1% alquiler a precio inferior al mercado.
- DB100 (urbanización): 52,7% zona muy poblada · 31,8% zona media · 15,5% zona poco poblada.

5.2 Distribución de variables clave

El análisis de las variables asociadas a la dimensión de pobreza muestra una asimetría marcada en la distribución de la renta disponible del hogar, con una cola derecha extensa que justifica el truncamiento aplicado en la visualización (Figura 2). La comparación de la renta entre hogares vulnerables y no vulnerables (Figura 3) evidencia una diferencia sustancial: la renta mediana de los hogares no vulnerables es de 37.680,25 €, frente a solo 11.910,30 € en los hogares vulnerables (menos de un tercio), con una dispersión notablemente menor en este último grupo. Los hogares vulnerables se concentran en un rango de renta bajo y homogéneo, mientras que el grupo no vulnerable presenta mucha más variabilidad, incluyendo un número considerable de valores atípicos de renta alta que elevan su media (43.401,23 €) muy por encima de su propia mediana.

En cuanto a la dimensión de exclusión financiera (Anexo D, Figura D.5), la gran mayoría de los hogares no presenta retrasos de pago (en torno al 96% en HS011, HS021 y HS031) ni carga financiera de deudas relevante (77,5% sin ninguna carga). Un patrón similar se observa en la capacidad para afrontar gastos imprevistos, donde el 67,0% de los hogares puede hacerlo sin dificultad. De hecho, el 61,4% de los hogares no tiene ningún indicador de exclusión activo. Sin embargo, un 38,6% de los hogares presenta al menos un indicador de exclusión financiera, lo que confirma que este fenómeno, aunque minoritario, afecta a una proporción suficientemente amplia de la muestra como para justificar su estudio combinado con la dimensión de pobreza.

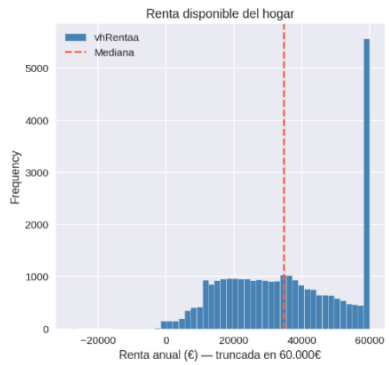


Figura 2: Distribución de la renta disponible y comparación por grupo de vulnerabilidad.

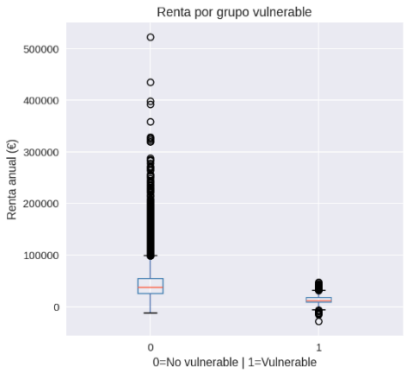


Figura 3: Comparación de la renta disponible por grupo de vulnerabilidad (boxplot).

5.3 Análisis de correlaciones

El análisis de correlaciones confirma la advertencia planteada al construir la matriz (Figura 4): las variables vhPobreza (0,801), vhMATDEP (0,278) y las variables exc_*/suma_exclusion (entre 0,084 y 0,440) muestran las correlaciones más altas con la variable objetivo, pero esto no indica que sean buenas variables predictoras, son las dimensiones con las que se construyó el target (apartado 4), por lo que su alta correlación es esperable y no aporta información nueva de cara a la modelización.

De las variables que sí son candidatas reales a predictoras, destaca vhRentaa (-0,352, la renta disponible del hogar), que muestra la correlación más fuerte y en la dirección esperada: a mayor renta, menor vulnerabilidad. Le sigue HS040 (0,348, la incapacidad de permitirse unas vacaciones), y en menor medida HH050 (0,230, temperatura adecuada de la vivienda) y HS050 (0,178, capacidad de permitirse una alimentación adecuada).

Un resultado que vale la pena destacar adicionalmente es el de HB120 (número de miembros del hogar), cuya correlación simple con la variable objetivo es prácticamente nula (-0,008), a pesar de resultar una de las variables más influyentes tanto en el análisis de importancia de Random Forest (apartado 9.1) como en los coeficientes de la Regresión Logística (apartado 9.2). Esto no es una contradicción: la correlación mide solo la relación lineal directa entre dos variables consideradas de forma aislada, mientras que el efecto real del tamaño del hogar solo se hace visible una vez el modelo tiene en cuenta el resto de variables a la vez, en particular la renta.

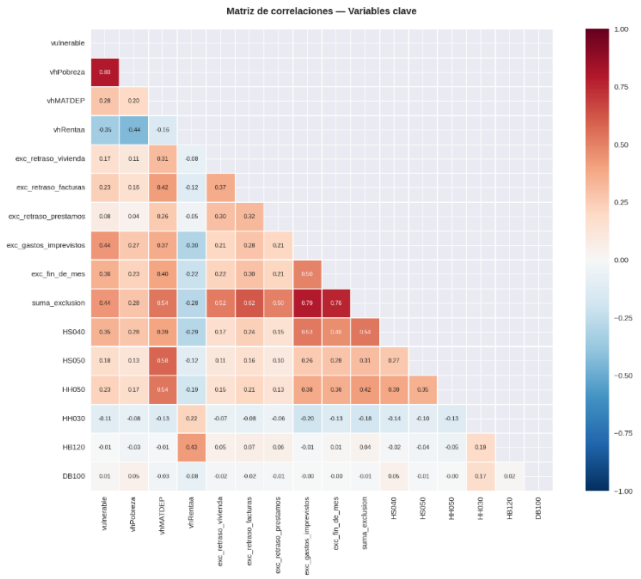


Figura 4: Matriz de correlaciones.

```
CORRELACIONES CON LA VARIABLE OBJETIVO (vulnerable)
============================================================
vhPobreza                0.801
suma_exclusion           0.440
exc_gastos_imprevistos   0.438
exc_fin_de_mes           0.355
vhRentaa                -0.352
HS040                    0.348
vhMATDEP                 0.278
exc_retraso_facturas     0.235
HH050                    0.230
HS050                    0.178
exc_retraso_vivienda     0.165
HH030                   -0.109
exc_retraso_prestamos    0.084
DB100                    0.014
HB120                   -0.008
```

Tabla 3: Listado de variables con correlación con la variable objetivo.

5.4 Análisis territorial por Comunidad Autónoma

El análisis por Comunidad Autónoma (Figura 5) muestra un patrón geográfico claro: el riesgo de vulnerabilidad se concentra en el sur y la periferia del país. Melilla (25,1%) y Ceuta (23,9%) presentan las tasas más altas, seguidas de Andalucía (19,0%), Extremadura (18,2%) y Murcia (18,1%). En el extremo opuesto, País Vasco (5,0%), Baleares (5,7%) y Navarra (6,1%) registran las tasas más bajas, junto con Madrid (7,2%) y Aragón (7,3%).

En general, este patrón coincide con el nivel de renta media autonómica anual (Figura 5): las comunidades de mayor riesgo tienden a tener rentas medias más bajas (Extremadura, 29.895 €, la más baja de toda la muestra) y las de menor riesgo, rentas más altas (Madrid, 48.243 €, la más alta). Sin embargo, Ceuta y Melilla constituyen una excepción notable: pese a tener una renta media relativamente alta (43.923 € y 41.892 €), presentan las tasas de vulnerabilidad más altas de toda España. Esto indica que, en estos dos territorios, el riesgo no está impulsado tanto por un nivel de renta bajo como por una mayor exclusión financiera: ambas comunidades presentan también los valores más altos de toda la tabla en el promedio de indicadores de exclusión activos (0,979 y 1,019 respectivamente), muy por encima incluso de Andalucía (0,915) o Canarias (0,906), las siguientes comunidades con mayor exclusión media. Esto indica una desigualdad interna o un coste de vida elevado no reflejado en la renta media autonómica. El detalle completo con las 19 comunidades, incluyendo la exclusión media, se recoge en el Anexo D (Tabla D.1).

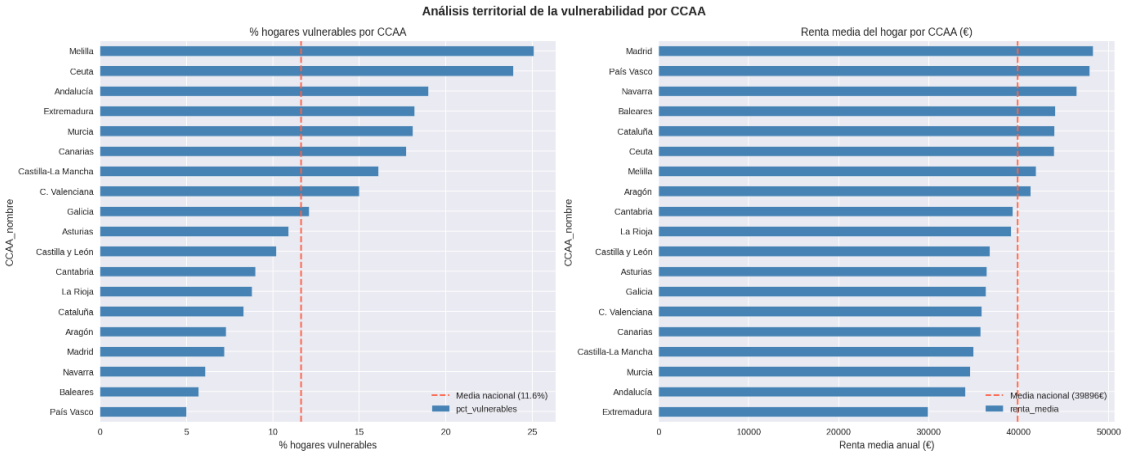


Figura 5: Análisis territorial y nivel de renta media por Comunidad Autónoma.

6. Preprocesamiento y transformación de datos

6.1 Tratamiento de valores nulos

El proceso de limpieza identificó valores en blanco codificados como espacios (' ') en catorce variables, que se convirtieron a valores nulos (NaN) para su correcto tratamiento estadístico. Un análisis detallado de estos valores nulos reveló que tres variables —retrasos en hipoteca/alquiler (57,8%), retrasos en préstamos (73,3%) y carga financiera de deudas (75,7%)— presentaban porcentajes de ausencia muy elevados que, en un primer análisis, podrían haberse interpretado como missings críticos que aconsejaran la eliminación de dichas variables.

Sin embargo, el cruce de estas variables con el régimen de tenencia de la vivienda confirmó que dichos valores en blanco no eran aleatorios, sino estructurales: correspondían a hogares para los que la pregunta no era aplicable (por ejemplo, un hogar propietario sin hipoteca no puede tener retrasos en su pago). En consecuencia, estos valores se imputaron con el código correspondiente a la ausencia del problema (por ejemplo, “no ha habido retrasos”), en lugar de tratarse como información faltante. El resto de variables con missings leves (por debajo del 5%) se imputaron mediante la moda, en el caso de las variables categóricas, y mediante la mediana, en el caso de la variable numérica número de habitaciones.

6.2 Codificación de variables categóricas

Las variables categóricas sin orden natural entre sus categorías (Comunidad Autónoma, tipo de vivienda, régimen de tenencia y tipo de hogar) se codificaron mediante la técnica One-Hot Encoding, generando una variable binaria por cada categoría (con exclusión de una categoría de referencia para evitar colinealidad perfecta). En este grupo se incluyeron también las variables de disponibilidad de ordenador y de vehículo (HS090, HS110). Aunque ambas están codificadas con números (1, 2, 3), su tercera categoría (no dispone del bien por un motivo distinto al económico) no representa un grado mayor de carencia que la segunda (no puede permitírselo), sino una razón distinta. Al no existir una progresión real entre ambas categorías, se trataron como variables nominales y no como una escala ordinal. Las variables que sí

seguían una escala con una progresión real, por ejemplo, la capacidad de afrontar gastos imprevistos o el grado de urbanización, se mantuvieron con su codificación numérica original.

6.3 Normalización de variables numéricas

Las variables continuas (renta disponible del hogar, número de habitaciones y número de miembros del hogar) y las variables ordinales se estandarizaron mediante la técnica StandardScaler, que transforma cada variable a media cero y desviación típica uno. Este paso resulta especialmente relevante para los algoritmos sensibles a la escala de las variables, como la Regresión Logística y el Support Vector Machine. El ajuste (fit) del escalador se realizó exclusivamente sobre el conjunto de entrenamiento, aplicando después la misma transformación al conjunto de prueba, con el fin de evitar la fuga de información entre ambos conjuntos.

6.4 Gestión del desbalanceo de clases

Con un 11,6% de hogares vulnerables, el dataset presenta un desbalanceo de clases moderado. Se optó por gestionar este desbalanceo mediante el ajuste de pesos de clase (class_weight = 'balanced') en los tres algoritmos de clasificación empleados, en lugar de recurrir a técnicas de sobremuestreo sintético como SMOTE. Esta decisión se justifica por dos motivos: en primer lugar, el nivel de desbalanceo no es lo suficientemente severo como para requerir la generación de observaciones sintéticas; en segundo lugar, evitar la creación de hogares artificiales simplifica la interpretación de los resultados del modelo.

Antes de aplicar cualquier transformación, el dataset se dividió en un conjunto de entrenamiento (80%, 23.495 hogares) y un conjunto de prueba (20%, 5.874 hogares), mediante muestreo aleatorio estratificado respecto a la variable objetivo y con una semilla fija (random_state = 42) para garantizar la reproducibilidad del estudio. La estratificación garantizó que el porcentaje de hogares vulnerables se mantuviera en el 11,6% tanto en el conjunto de entrenamiento como en el de prueba.

Un aspecto importante es que se excluyeron del conjunto de variables predictoras, aquellas variables utilizadas directamente en la construcción de la variable objetivo (riesgo de pobreza y los cinco indicadores de exclusión financiera), así como la variable de carencia material severa, por estar muy relacionada con el target. La inclusión de estas variables como predictoras habría generado una fuga de información (data leakage), permitiendo a los modelos “adivinar” el target a partir de su propia definición, en lugar de aprender patrones predictivos a partir de características indirectas del hogar. Tras esta exclusión, el conjunto final de variables predictoras quedó compuesto por 14 variables, que tras la codificación categórica dieron lugar a 50 columnas finales en la matriz de trabajo.

Identificar estas variables no es algo automático: hace falta entender qué significa cada una y cómo se relaciona con la definición del target, algo que una herramienta de modelización automática (AutoML) no haría por sí sola, ya que este tipo de herramientas suele fijarse solo en criterios estadísticos, como la correlación, y no en el sentido real de cada variable. Un buen ejemplo es la exclusión de la carencia material severa (vhMATDEP): esta variable no

forma parte de la fórmula del target, así que una detección automática de fuga de información, basada solo en esa fórmula, no la habría marcado como problemática. Aun así, se excluyó por precaución, al estar conceptualmente muy cerca de la dimensión de pobreza que sí forma parte del target, evitando así una fuga de información más difícil de detectar solo con métodos estadísticos.

7. Modelización

7.1 Regresión Logística

Se entrenó una Regresión Logística con ajuste de pesos de clase (class_weight = 'balanced'), cuyo hiperparámetro de regularización C se optimizó mediante búsqueda en rejilla (GridSearchCV) con validación cruzada estratificada de 5 particiones, resultando en C = 500 como el valor con mejor rendimiento. Los resultados obtenidos son: ROC-AUC de 0,975, F1-score de 0,737, recall de 0,965 y precisión de 0,596.

Este recall tan alto (0,965) significa que el modelo identifica correctamente al 96,5% de los hogares realmente vulnerables, aunque a cambio la precisión baja un poco (59,6%): genera un número considerable de falsos positivos. Este es un comportamiento típico cuando se ajustan los pesos de clase en un modelo lineal, y tiene sentido en casos donde es peor no detectar a un hogar vulnerable que revisar de más algún hogar que al final no lo era, por ejemplo, cuando se reparten ayudas sociales para cubrir necesidades básicas.

7.2 Random Forest

El segundo modelo evaluado es un Random Forest, también con ajuste de pesos de clase, cuyos hiperparámetros (profundidad máxima y número mínimo de observaciones por hoja) se optimizaron mediante búsqueda en rejilla, resultando en max_depth = 20 y min_samples_leaf = 1. Los resultados obtenidos son: ROC-AUC de 0,981 (el más alto de los tres modelos), F1-score de 0,795 (el más alto de los tres modelos), recall de 0,803 y precisión de 0,788 (la más alta de los tres modelos).

A diferencia de la Regresión Logística, Random Forest ofrece el comportamiento más equilibrado entre ambos tipos de error: detecta a cuatro de cada cinco hogares vulnerables reales (80,3%), y cuando predice que un hogar es vulnerable, acierta cerca del 79% de las veces. Este equilibrio es mejor en comparación con los otros dos modelos, y es la razón por la que se elige como modelo definitivo (apartado 8.3).

7.3 Support Vector Machine (SVM)

El tercer modelo evaluado es un SVM con ajuste de pesos de clase, cuyos hiperparámetros óptimos se determinaron mediante búsqueda en rejilla (GridSearchCV) sobre los kernels lineal y RBF y distintos valores del parámetro de regularización C. La combinación seleccionada fue kernel lineal con C = 100, este resultado aportó una conclusión relevante: la frontera que separa los hogares vulnerables y no vulnerables es, en gran medida, lineal, ya que el kernel lineal superó al kernel RBF (no lineal) en la búsqueda de hiperparámetros.

Los resultados obtenidos son: ROC-AUC de 0,974, F1-score de 0,738, recall de 0,987 (el más alto de los tres modelos) y precisión de 0,590 (la más baja de los tres modelos). Este modelo lleva al extremo el comportamiento observado en la Regresión Logística, con un recall casi perfecto a costa de la precisión más baja de los tres modelos. El hecho de que SVM (con kernel lineal) y la Regresión Logística se comporten de forma tan parecida confirma que los dos, al ser modelos lineales, llegan a soluciones muy similares, y que introducir un modelo más complejo matemáticamente no mejora la capacidad de predicción de forma relevante.

7.4 Clustering no supervisado con K-Means

Con el fin de identificar perfiles socioeconómicos dentro del conjunto de hogares, se aplicó el algoritmo K-Means sobre el conjunto completo de datos preprocesados (no solo el conjunto de entrenamiento, ya que el objetivo de esta técnica es descriptivo y no predictivo). El número óptimo de clusters se determinó combinando el método del codo y el coeficiente de silueta, evaluando valores de k entre 2 y 8, y verificando la estabilidad del resultado con 30 inicializaciones aleatorias del algoritmo (n_init = 30).

Al usar todas las variables preprocesadas (50 columnas), el coeficiente de silueta salió bastante bajo, sin ninguna zona donde se estabiliza claramente. Esto se debe, en gran parte, a las dos variables categóricas con más categorías: Comunidad Autónoma (19) y tipo de hogar (14). Al codificarlas con One-Hot, se generan muchas columnas nuevas que añaden ruido al cálculo de las distancias entre hogares, dificultando que el algoritmo encuentre grupos bien diferenciados. Por eso se repitió el análisis quitando estas dos variables del clustering; se siguen usando después para describir los perfiles, pero ya no entran como variables de entrada del algoritmo. Con este cambio (19 columnas en total), la segmentación con k = 3 obtiene un silhouette de 0,212, bastante mejor que con todas las variables, así que se elige como la versión definitiva.

Al aplicar el modelo final con k = 3, se obtienen estos tres grupos (clusters). La tabla siguiente resume, para cada uno, su tasa de vulnerabilidad, su renta media y qué proporción de hogares vive en alquiler. La interpretación detallada de estos perfiles se desarrolla en el apartado 9.3.

Cluster	Hogares	% Vulnerab.	Renta media	% Alquiler
1 - Acomodados	19.514	3,6%	46.193 €	11,5%
0 - Renta baja	8.331	26,0%	27.652 €	23,1%
2 - Máximo riesgo	1.524	36,0%	26.199 €	31,2%

8. Evaluación y comparación de modelos

8.1 Métricas de evaluación

La comparación de los modelos se ha realizado sobre cuatro métricas complementarias: el área bajo la curva ROC (ROC-AUC), que mide la capacidad discriminativa global del modelo con independencia del umbral de clasificación; el F1-score, que combina precisión y sensibilidad en una única medida; el recall (sensibilidad), que indica la proporción de hogares vulnerables reales correctamente identificados; y la precisión, que indica la proporción de

predicciones positivas que son realmente correctas. La elección de estas métricas, en lugar de la exactitud (accuracy), responde al desbalanceo de clases del problema, que haría de la exactitud una métrica poco informativa; un problema documentado en la literatura sobre aprendizaje con datos desbalanceados (He y Garcia, 2009).

8.2 Comparativa de resultados

La tabla siguiente resume los resultados de validación cruzada (5-fold) de los tres modelos supervisados evaluados:

Modelo	ROC-AUC	F1-score	Recall	Precisión
Regresión Logística	0,975	0,737	0,965	0,596
Random Forest	0,981	0,795	0,803	0,788
SVM (kernel lineal)	0,974	0,738	0,987	0,590

8.3 Selección del modelo óptimo

Los tres modelos tienen un rendimiento muy parecido y bastante alto en cuanto al ROC-AUC (entre 0,974 y 0,981), así que esta métrica sola no basta para decidir cuál elegir: hay que fijarse también en cómo se equilibran el recall y la precisión, y qué es lo que más importa para el uso que se le va a dar al modelo.

Se elige Random Forest como modelo principal de este trabajo, porque es el que mejor equilibra los dos tipos de error: tiene el F1-score más alto de los tres (0,795), el ROC-AUC más alto (0,981) y también la precisión más alta (0,788), lo que significa muchos menos falsos positivos que los otros dos modelos. En cuanto a la interpretabilidad, que antes era una ventaja de los modelos lineales, ahora también está cubierta con Random Forest, gracias a los valores SHAP calculados directamente sobre este modelo (apartado 11.3), así que ya no hace falta elegir un modelo más simple solo para poder explicar sus resultados.

Aun así, si lo más importante fuera no dejar pasar ni un solo hogar vulnerable, aunque eso suponga revisar muchos casos que al final no lo eran, la Regresión Logística o el SVM seguirían siendo buenas opciones, ya que tienen un recall bastante más alto (0,965 y 0,987, frente al 0,803 de Random Forest). Por eso se mantiene el análisis de los coeficientes de la Regresión Logística en el apartado 9.2, como una segunda mirada útil para interpretar los resultados.

9. Interpretabilidad de resultados

9.1 Feature importance (Random Forest)

El análisis de importancia de variables del Random Forest muestra que la renta disponible del hogar (vhRentaa) es, con diferencia, el predictor más influyente, con el 49,7% de la importancia total del modelo. La capacidad de permitirse unas vacaciones (HS040) es la segunda variable más relevante (12,3%), seguida del número de miembros del hogar (HB120, 6,1%). La siguiente tabla recoge las 10 variables más relevantes:

Variable	Importancia
vhRentaa (renta disponible)	49,7%

HS040 (puede permitirse vacaciones)	12,3%
HB120 (nº de miembros del hogar)	6,1%
HH050 (temperatura adecuada)	3,1%
HH030 (nº de habitaciones)	2,5%
HS110 = no dispone (no puede permitírselo)	2,0%
HS090 = no dispone (no puede permitírselo)	1,6%
HH021 = alquiler a precio de mercado	1,3%
DB100 (grado de urbanización)	1,2%
HS050 (puede permitirse proteína)	1,2%

Un resultado especialmente valioso surge de la codificación de las variables de disponibilidad de ordenador y vehículo (HS090, HS110) como variables separadas por categoría (apartado 6.2): el análisis distingue la contribución de cada una, mostrando que la carencia por motivos económicos ("no puede permitírselo") pesa aproximadamente el doble que la carencia por otros motivos, tanto en HS110 (2,0% frente a 1,0%) como en HS090 (1,6% frente a 0,9%). Esto confirma que tratar estas dos variables como nominales, en lugar de como una escala ordinal simple, fue la decisión correcta: ambas categorías de "no" no significan lo mismo de cara a predecir la vulnerabilidad.

El resto del top 15 recoge indicadores adicionales de privación material, régimen de tenencia (alquiler a precio de mercado) y composición del hogar, confirmando que el modelo capta señales genuinas de exclusión financiera más allá de la renta, lo cual es coherente con el papel del alquiler identificado en el análisis de clusters (apartado 9.3).

9.2 Coeficientes de la Regresión Logística

Aunque el modelo elegido como principal es Random Forest (apartado 8.3), también se miran los coeficientes de la Regresión Logística, porque se pueden leer directamente y sirven como una segunda forma de comprobar los resultados.

Antes de nada, hay que aclarar el coeficiente de la renta (vhRentaa): salió -11,72 (odds ratio ≈0,000008), un número demasiado extremo para tomarlo al pie de la letra. Esto ocurre porque la renta y la dimensión de pobreza del target están casi pegadas matemáticamente, lo que dispara el coeficiente durante el ajuste, un efecto esperado por cómo se construyó el target, no un fallo del modelo. Lo que sí se puede afirmar con seguridad es la idea general: a mayor renta, mucho menor riesgo.

El resto de los coeficientes sí se pueden interpretar con normalidad, y se resumen en la siguiente tabla:

Variable	Efecto	Odds ratio
HB120 (nº de miembros)	↑ Aumenta el riesgo	15,65
DB040 = Ceuta	↑ Aumenta el riesgo	2,43
DB040 = Melilla	↑ Aumenta el riesgo	2,42
HS040 (no puede permitirse vacaciones)	↑ Aumenta el riesgo	1,86
DB040 = Castilla-La Mancha	↑ Aumenta el riesgo	1,86
DB040 = Navarra	↓ Reduce el riesgo	0,79
HX060 = 1 adulto con 1 hijo dependiente	↓ Reduce el riesgo	0,78
DB040 = País Vasco	↓ Reduce el riesgo	0,75
HX060 = 2 adultos sin hijos, ambos <65	↓ Reduce el riesgo	0,73
HX060 = 2 adultos sin hijos, uno 65+	↓ Reduce el riesgo	0,68

Lo primero que llama la atención, después de la renta, es que el número de miembros del hogar (HB120) es el que más sube el riesgo (odds ratio 15,65), esto ya se había visto tanto en los clusters como en el Random Forest, y aquí se repite otra vez. Después aparecen varias comunidades autónomas subiendo el riesgo: Ceuta, Melilla y Castilla-La Mancha, que son justo las mismas que ya salían como las más vulnerables en el análisis territorial (apartado 10). Y al revés, Navarra y País Vasco son comunidades que bajan el riesgo, lo cual también coincide con lo que se vio en ese mismo análisis. El hecho de que dos partes distintas del trabajo, los coeficientes por un lado, los datos reales por otro, coincidan en sus resultados es una buena señal de que el modelo tiene sentido.

También se ve que varios tipos de hogares con menos personas (una persona sola, o dos adultos sin hijos) aparecen reduciendo el riesgo. Esto encaja con cómo el INE calcula el riesgo de pobreza: a un hogar con menos miembros le hace falta proporcionalmente menos dinero para no entrar en esa categoría, así que tiene sentido que estos hogares salgan con menos riesgo en el modelo.

9.3 Perfiles de vulnerabilidad identificados

La segmentación obtenida con K-Means (apartado 7.4) sirve para completar los resultados de los modelos supervisados con una mirada más descriptiva sobre los distintos tipos de hogares que hay en la muestra. Los tres clusters encontrados muestran una diferencia clara en su nivel de vulnerabilidad (entre el 3,6% y el 36,0%), aunque la separación estadística entre ellos sea poca (silhouette = 0,212).

El Cluster 1 (19.514 hogares, el 66% de la muestra) agrupa a los hogares más acomodados: renta alta (46.193 €) y poco alquiler (11,5%). Es, con diferencia, el grupo con menos vulnerabilidad de los tres (3,6%).

El hallazgo más interesante para pensar en políticas de ayuda aparece al comparar los Clusters 0 y 2. Ambos tienen una renta muy parecida entre sí (27.652 € y 26.199 €), pero una vulnerabilidad bastante distinta (26,0% y 36,0%). La diferencia entre los dos no está en la renta, sino en cuántos hogares viven de alquiler: 23,1% en el Cluster 0, frente a 31,2% en el Cluster 2, el más vulnerable de los tres. Esto confirma, con una técnica completamente distinta a la de los apartados anteriores, que vivir de alquiler añade un riesgo que no depende solo del nivel de ingresos de cada hogar, algo que ya se había visto tanto en el análisis por régimen de tenencia (apartado 5.4.2) como en los coeficientes del apartado 9.2.

Es importante mencionar que el silhouette obtenido (0,212) sigue sin ser muy alto, así que estos tres perfiles ayudan a explicar los resultados de forma sencilla, pero no representan grupos que estén muy separados de forma natural en los datos. Aun así, la diferencia tan grande en vulnerabilidad entre clusters (3,6% frente a 36,0%) demuestra que esta segmentación sí aporta algo útil de verdad.

10. Visualización territorial de resultados

Para comparar el patrón territorial que ya se vio en el análisis exploratorio (apartado 5.4) con lo que predice el modelo, se calcularon las probabilidades de vulnerabilidad que da Random Forest para todos los hogares, agrupadas por Comunidad Autónoma. La siguiente tabla compara la vulnerabilidad real con el riesgo medio que predice el modelo, ordenada de mayor a menor riesgo predicho:

CCAA	Hogares	Vulner. real	Riesgo predicho
Melilla	187	25,1%	25,7%
Ceuta	209	23,9%	23,1%
Extremadura	1.079	18,2%	21,7%
Andalucía	3.206	19,0%	21,1%
Murcia	1.173	18,1%	20,2%
Canarias	1.059	17,7%	19,4%
Castilla-La Mancha	1.200	16,1%	18,6%
C. Valenciana	2.308	15,0%	17,7%
Galicia	1.630	12,1%	16,3%
Asturias	1.051	10,9%	13,6%
Castilla y León	1.662	10,2%	12,9%
Cantabria	853	9,0%	11,8%
La Rioja	729	8,8%	10,8%
Cataluña	5.938	8,3%	10,1%
Aragón	1.198	7,3%	9,2%
Madrid	2.861	7,2%	8,8%
Baleares	819	5,7%	7,9%
Navarra	797	6,1%	7,7%
País Vasco	1.410	5,0%	6,5%

El patrón territorial se ve muy claro, y encaja con lo que se sabe sobre la geografía socioeconómica de España: el riesgo se concentra en el sur y la periferia (Melilla, Ceuta, Extremadura, Andalucía, Murcia, Canarias), y es mucho más bajo en el norte y en el centro económico del país (País Vasco, Navarra, Baleares, Madrid). El orden que da el modelo coincide casi perfectamente con el orden real que se observa en los datos.

Eso sí, las probabilidades del modelo salen, en la mayoría de comunidades, entre 1,5 y 4,2 puntos por encima de la vulnerabilidad real, debido al ajuste de pesos de clase (class_weight = 'balanced'). Ceuta es la única excepción, con una predicción algo por debajo de la realidad, probablemente por su tamaño muestral reducido (209 hogares). Como este sesgo no desaparece del todo, se mantiene el mismo criterio de la aplicación (apartado 11): mostrar una categoría de riesgo en vez de un porcentaje exacto, para no transmitir una falsa precisión.

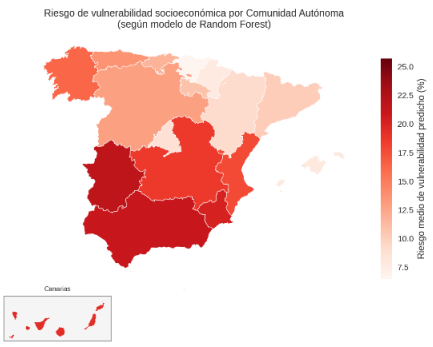


Figura 6: Mapa de riesgo de vulnerabilidad por Comunidad Autónoma (modelo Random Forest).

11. Productivización del modelo

11.1 Desarrollo de la aplicación en Gradio

Para poner el modelo en producción se construyó una aplicación interactiva con la librería Gradio, que se ejecuta directamente desde Google Colab. La aplicación tiene tres partes.

La primera es una función que recibe los datos de un hogar (predecir_vulnerabilidad), pero en un formato fácil de entender; por ejemplo, el nombre de la Comunidad Autónoma o "Sí"/"No", en vez de códigos numéricos. Esta función traduce esos datos a la codificación original con los mismos diccionarios que ya se usaron en el análisis exploratorio, les aplica el mismo preprocesamiento que se ajustó durante el entrenamiento, y obtiene la predicción del modelo principal, Random Forest.

La segunda parte se encarga de clasificar el riesgo. En lugar de mostrar la probabilidad tal cual la da el modelo, que, como se explicó en la sección 10, está sesgada al alza, calcula en qué percentil de riesgo se sitúa ese hogar respecto a los casi 29.000 hogares del dataset, y lo traduce en una categoría sencilla: Bajo, Medio o Alto.

La tercera parte es la interfaz que ve el usuario, hecha con los componentes de Gradio. Tiene desplegables para las variables categóricas (Comunidad Autónoma, urbanización, régimen de tenencia, tipo de vivienda, tipo de hogar), deslizadores para las numéricas (renta, número de habitaciones, número de miembros, carga de deudas) y botones para las de privación material: unos con dos opciones (vacaciones, alimentación, temperatura) y otros con tres (ordenador y vehículo: "Sí" / "No, no puede permitírselo" / "No, por otro motivo"), reflejando la relevancia de la distinción que se realizó en el análisis de importancia de variables (apartado 9.1). El resultado final se muestra en un panel de texto con la categoría de riesgo, la probabilidad estimada, la posición relativa del hogar y una nota que recuerda el sesgo de calibración del modelo.

11.2 Demostración funcional

Para comprobar que la aplicación funciona bien, se probó con dos hogares muy distintos entre sí:

Perfil de prueba	Categoría	Probabilidad	Posición relativa
Hogar de bajo riesgo (renta alta, sin deudas)	🟢 Bajo	0,3%	Más riesgo que el 21% de los hogares
Hogar de alto riesgo (renta baja, con deudas)	🔴 Alto	82,9%	Más riesgo que el 93% de los hogares

La diferencia entre los dos casos es muy clara, tanto en la categoría como en la posición relativa. Esto confirma que todo el proceso funciona bien de principio a fin: los diccionarios que traducen los datos, el preprocesamiento y el modelo ya entrenado.

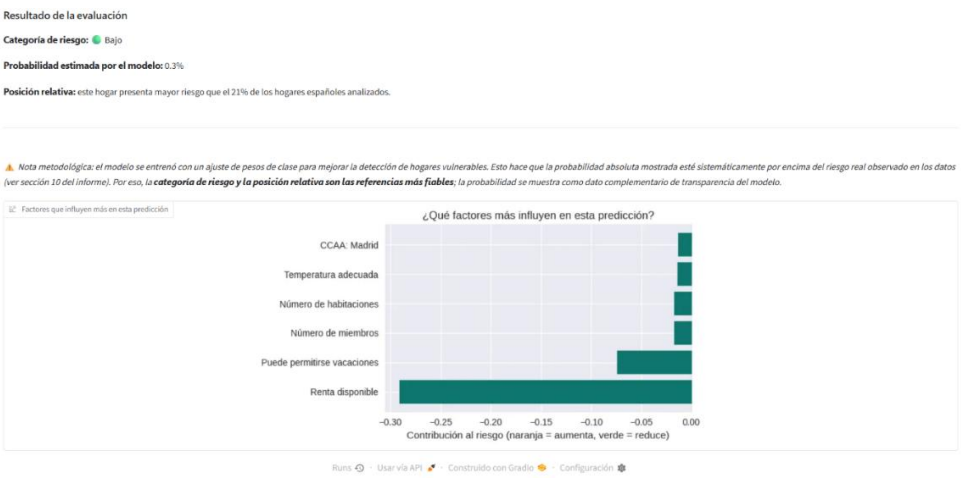


Figura 7: Ejemplo de hogar de bajo riesgo en la aplicación Gradio.



Figura 8: Ejemplo de hogar de alto riesgo en aplicación Gradio.

11.3 Explicabilidad individual (SHAP)

En el hogar de bajo riesgo, el gráfico de SHAP muestra que lo que más ayuda a que su riesgo sea bajo es, con diferencia, la renta disponible, seguida de poder permitirse vacaciones. El resto de factores también ayudan a bajar el riesgo, pero mucho menos.

En el hogar de alto riesgo, la renta disponible vuelve a ser lo que más pesa, pero ahora en sentido contrario: es lo que más sube el riesgo. Después influyen no poder permitirse vacaciones, y no tener coche ni ordenador por no poder pagarlos. Hay dos factores que llaman la atención porque bajan el riesgo, en vez de subirlo como cabría esperar: vivir en Extremadura, y tener carga financiera de deudas.

Este segundo caso tiene una explicación interesante, aunque al principio parezca raro. Se pensaría que "no tener deudas" es siempre bueno, y "tener una deuda pesada" es siempre malo. Pero para un hogar que ya lo tiene todo muy difícil, sin apenas renta, sin poder permitirse casi nada, no tener ninguna deuda puede significar dos cosas muy distintas: que le va bien económicamente, o que ningún banco le presta dinero porque no se fía de que pueda devolverlo. En este segundo caso, "no tener deudas" no es una buena señal, es un

síntoma de que está tan excluido del sistema financiero que ni siquiera puede pedir un préstamo.

Por eso, que este hogar sí tenga una deuda (aunque sea "pesada") puede indicar que, en algún momento, un banco confió lo suficiente en él como para prestarle dinero, un pequeño signo de acceso al sistema financiero que un hogar completamente excluido ni siquiera tendría la opción de tener. Este es un buen ejemplo de por qué SHAP es útil en la aplicación: ayuda a descubrir este tipo de relaciones, que no son tan obvias si solo se piensa "a más deuda, peor".

12. Conclusiones

12.1 Principales hallazgos

Este trabajo desarrolla un proceso completo para predecir qué hogares españoles tienen más riesgo de vulnerabilidad socioeconómica, usando los datos de la ECV 2025. Los hallazgos más importantes se pueden resumir en cinco puntos.

Primero, la variable objetivo (hogar "doblemente vulnerable": en riesgo de pobreza y con al menos un problema de exclusión financiera) afecta al 11,6% de los hogares de la muestra (3.415 de 29.369). Al construirla, se vio que la pobreza y la exclusión financiera no siempre van juntas: hay hogares pobres sin problemas de pago, y hogares con problemas de pago que no son pobres. Esto confirma que tiene sentido estudiar las dos cosas juntas, en vez de fijarse solo en el indicador oficial de pobreza.

Segundo, los tres modelos probados obtienen un rendimiento alto y bastante parecido entre sí. Se elige Random Forest como modelo principal porque es el que mejor equilibra el acierto entre los dos tipos de error posibles. El hecho de que el SVM funcione mejor con una frontera lineal confirma que la línea que separa a los hogares vulnerables de los que no lo son es, en gran medida, recta.

Tercero, tanto Random Forest como la Regresión Logística coinciden en que la renta del hogar es, con diferencia, lo que más pesa a la hora de predecir el riesgo. Aun así, otras cosas como poder permitirse vacaciones, el número de miembros del hogar, o tener coche u ordenador, también ayudan a predecir, sobre todo la parte de exclusión financiera, que no depende solo de cuánto dinero entra en cada hogar.

Cuarto, tanto el análisis por comunidades como la segmentación de hogares llegan a la misma conclusión: el riesgo se concentra en el sur y la periferia de España (Melilla, Ceuta, Extremadura, Andalucía, Murcia, Canarias), y es más bajo en el norte y el centro económico (País Vasco, Navarra, Baleares, Madrid). Además, la segmentación de hogares deja un hallazgo interesante: entre los hogares de renta baja, lo que más marca la diferencia en vulnerabilidad no es la renta en sí, sino si viven de alquiler o no. Esto sugiere que las ayudas sociales deberían tener en cuenta si el hogar alquila su vivienda, no solo cuánto gana.

Por último, el modelo se llevó a la práctica con una aplicación en Gradio, probada con casos de riesgo bien distintos. En vez de un porcentaje exacto (que podría dar una falsa sensación

de precisión), muestra una categoría de riesgo y compara al hogar con el resto de España, además de una explicación individual con los factores que más influyen en cada predicción.

12.2 Limitaciones del estudio

Este trabajo tiene varias limitaciones que conviene tener en cuenta.

La primera es que se usan datos de un único año, así que no se puede saber si la vulnerabilidad de un hogar es algo pasajero (por ejemplo, perder el trabajo un tiempo) o algo más permanente. La segunda es que no se incluyeron los ficheros de personas de la ECV, así que se dejaron fuera datos como la edad, el sexo, el nivel de estudios o la situación laboral de quien más aporta al hogar, datos que probablemente habrían ayudado a predecir mejor.

La tercera limitación tiene que ver con el coeficiente de la renta en la Regresión Logística: salió un número tan extremo que no se puede leer al pie de la letra, porque la renta y la parte de pobreza del target están casi pegadas matemáticamente entre sí. Por eso ese coeficiente solo se puede interpretar de forma general (más renta, menos riesgo), no como un multiplicador exacto. La cuarta es que el ajuste de pesos de clase, necesario para que los modelos detectaran bien a los hogares vulnerables, hace que las probabilidades que da el modelo salgan infladas. Esto se solucionó mostrando una categoría de riesgo y una posición relativa en vez del porcentaje exacto, pero significa que esas probabilidades no se pueden usar directamente para cálculos precisos, como repartir un presupuesto concreto.

Por último, la segmentación con K-Means no separa los grupos de forma muy nítida (silhouette = 0,212), algo esperable dado que se mezclan variables numéricas y categóricas. Por eso los tres perfiles encontrados hay que verlos como una forma útil de explicar los resultados, no como grupos que existan de forma completamente separada en la realidad.

12.3 Líneas de mejora futura

- Incorporar variables a nivel de persona (ficheros R y P) agregadas al nivel de hogar, en particular características del sustentador principal (edad, nivel educativo, situación laboral).

- Explorar la evolución temporal de la vulnerabilidad combinando ediciones anuales sucesivas de la ECV, lo que permitiría distinguir vulnerabilidad estructural de coyuntural.

- Recalibrar las probabilidades del modelo mediante técnicas como Platt scaling o regresión isotónica, para poder ofrecer estimaciones de probabilidad absoluta fiables además de la categorización relativa ya implementada en la aplicación.

- Evaluar técnicas de modelización adicionales, como gradient boosting (XGBoost, LightGBM), para contrastar si superan el techo de rendimiento alcanzado por los tres modelos lineales y de ensemble evaluados.

- Explorar técnicas de clustering más adecuadas para variables mixtas (por ejemplo, K-Prototypes) o de reducción de dimensionalidad previa (como el Análisis de

Correspondencias Múltiples), que podrían mejorar la separación entre los perfiles identificados en el apartado 9.3.

13. Bibliografía

Abid, A. et al. (2019). Gradio: Hassle-Free Sharing and Testing of ML Models in the Wild. https://gradio.app

Eurostat. EU Statistics on Income and Living Conditions (EU-SILC) methodology. https://ec.europa.eu/eurostat/web/income-and-living-conditions/methodology

He, H., & Garcia, E. A. (2009). Learning from Imbalanced Data. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263-1284.

Instituto Nacional de Estadística. Encuesta de Condiciones de Vida (ECV). Cuestionario de Hogar 2025. https://www.ine.es/metodologia/t25/ecv_hog25.pdf

Instituto Nacional de Estadística (2020). Encuesta de Condiciones de Vida (ECV). Diseño de registro y descripción de variables. https://www.ine.es/metodologia/t25/diseño_registro_ecv.pdf

Instituto Nacional de Estadística. Encuesta de Condiciones de Vida (ECV). Informes Metodológicos Estandarizados. https://ine.es/dynt3/metadatos/es/RespuestaPrint.html?oper=155

Instituto Nacional de Estadística. Encuesta de Condiciones de Vida (ECV). Metodología. https://www.ine.es/daco/daco42/condivi/ecv_metodo.pdf

Instituto Nacional de Estadística. Encuesta de Condiciones de Vida (ECV). Microdatos. Ficheros transversales, año 2025. https://www.ine.es/dyngs/INEbase/operacion.htm?c=Estadistica_C&cid=1254736176807&menu=resultados&idp=1254735976608

Instituto Nacional de Estadística. Población en riesgo de pobreza relativa. Metodología del umbral de pobreza. https://www.ine.es/uc/Th2qtfFx

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830. https://scikit-learn.org

Anexos

Anexo A: Código completo (Jupyter Notebook)

El código completo del trabajo se adjunta como notebook exportado a formato HTML (archivo TFM_Lina_Maria_Caro_Perdomo.html), entregado junto con este documento, según lo indicado en las directrices del TFM. Adicionalmente, el notebook puede consultarse en su entorno original de Google Colab en el siguiente enlace: https://drive.google.com/file/d/16D1XktVMNBPRbwZz4z5W3O9lwEkUbWjc/view?usp=sharing

Anexo B: Diccionario de variables utilizadas

Variable	Descripción	Codificación
DB030	Identificador único del hogar	Numérico (uso interno, no predictor)
DB040	Comunidad Autónoma	Código NUTS2 (19 categorías)
DB100	Grado de urbanización	1=Muy poblada, 2=Media, 3=Poco poblada
vhPobreza	Hogar en riesgo de pobreza (excluida del modelo)	0/1
vhMATDEP	Carencia material severa (excluida del modelo)	0/1
vhRentaa	Renta disponible total del hogar	€ (continua)
HS011	Retrasos hipoteca/alquiler (excluida, usada en target)	1=Sí 1 vez, 2=Sí 2+, 3=No
HS021	Retrasos en facturas (excluida, usada en target)	1=Sí 1 vez, 2=Sí 2+, 3=No
HS031	Retrasos en préstamos (excluida, usada en target)	1=Sí 1 vez, 2=Sí 2+, 3=No
HS060	Capacidad afrontar gastos imprevistos (excluida)	1=Sí, 2=No
HS120	Capacidad de llegar a fin de mes (excluida)	Escala 1=Mucha dificultad a 6=Mucha facilidad
HS150	Carga financiera de deudas (predictora)	1=Pesada, 2=Razonable, 3=Ninguna
HS040	Puede permitirse vacaciones	1=Sí, 2=No
HS050	Puede permitirse proteína cada 2 días	1=Sí, 2=No
HH050	Puede mantener temperatura adecuada	1=Sí, 2=No
HS090	Dispone de ordenador	1=Sí, 2=No (no puede permitírselo), 3=No (otro motivo)
HS110	Dispone de coche	1=Sí, 2=No (no puede permitírselo), 3=No (otro motivo)
HH010	Tipo de vivienda	1 = Unifamiliar independiente · 2 = Unifamiliar adosada o pareada · 3 = Piso en edificio con menos de 10 viviendas · 4 = Piso en edificio con 10 viviendas o más

HH021	Régimen de tenencia	1 = Propiedad sin hipoteca · 2 = Propiedad con hipoteca · 3 = Alquiler a precio de mercado · 4 = Alquiler a precio inferior al de mercado · 5 = Cesión gratuita
HH030	Número de habitaciones	Numérica discreta
HB120	Número de miembros del hogar	Numérica discreta
HX060	Tipo de hogar (composición)	1 = Hombre solo (<30) · 2 = Hombre solo (30-64) · 3 = Hombre solo (65+) · 4 = Mujer sola (<30) · 5 = Mujer sola (30-64) · 6 = Mujer sola (65+) · 7 = 2 adultos sin hijos, uno de 65+ · 8 = 2 adultos sin hijos, ambos <65 · 9 = Otros hogares sin hijos dependientes · 10 = 1 adulto con 1+ hijo dependiente · 11 = 2 adultos con 1 hijo dependiente · 12 = 2 adultos con 2 hijos dependientes · 13 = 2 adultos con 3+ hijos dependientes · 14 = Otros hogares con hijos dependientes

Las variables marcadas como "excluida" no forman parte del conjunto final de predictoras del modelo, por su papel en la construcción de la variable objetivo (ver apartado 6.4).

Anexo C: Resultados detallados de los modelos

Las matrices de confusión de los tres modelos, evaluadas sobre el conjunto de test (5.874 hogares, 683 hogares vulnerables reales), se recogen a continuación:

Modelo	VN	FP	FN	VP	Recall (test)	Precisión (test)
Regresión Logística	4.724	467	27	656	0,960	0,584
Random Forest	5.020	171	115	568	0,832	0,768
SVM (kernel lineal)	4.697	494	16	667	0,977	0,575

VN = verdaderos negativos, FP = falsos positivos, FN = falsos negativos, VP = verdaderos positivos. Las métricas de recall y precisiones calculadas sobre el conjunto de test son consistentes con los valores obtenidos por validación cruzada en la sección 8.2, confirmando la estabilidad de los tres modelos fuera de la muestra de entrenamiento. Random Forest presenta el equilibrio más favorable entre ambos tipos de error (115 falsos negativos y 171 falsos positivos), resultando en la mayor precisión de los tres modelos en el conjunto de test (76,8%) sin sacrificar en exceso la sensibilidad (83,2%). Regresión Logística y SVM, en cambio, cometen muy pocos falsos negativos (27 y 16 respectivamente) a costa de un número considerable de falsos positivos (467 y 494).

Las curvas ROC, con zoom en la región de bajo FPR, muestran a Random Forest claramente por encima de los otros dos modelos en casi todo el rango representado, mientras que Regresión Logística y SVM se mantienen muy próximos entre sí, coherente con el hallazgo de que ambos convergen a un comportamiento similar al tratarse, en la práctica, de fronteras de decisión lineales. Esta separación visual respalda la elección de Random Forest como modelo principal (apartado 8.3), más allá de la comparación numérica de la tabla 8.2.

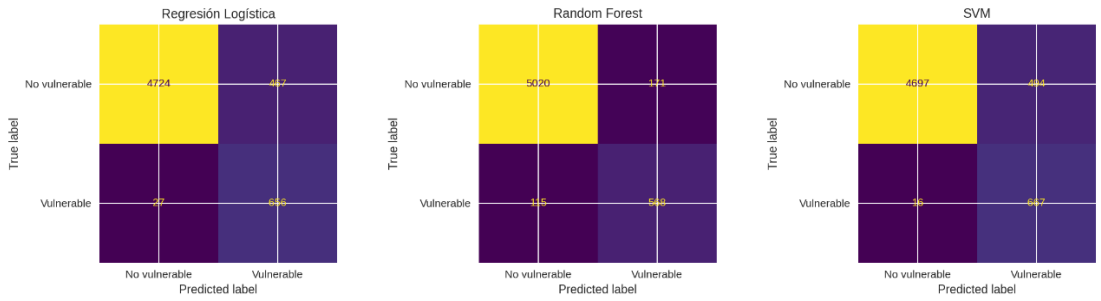


Figura C.1: Matrices de confusión de los tres modelos (Regresión Logística, Random Forest y SVM) sobre el conjunto de test.

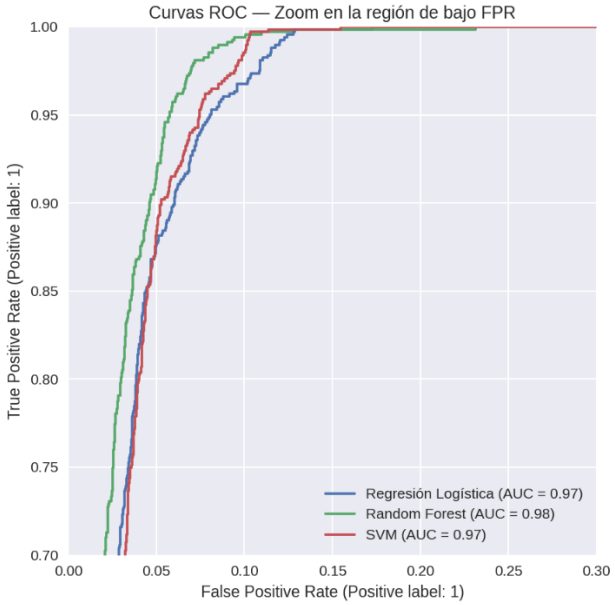


Figura C.2: Curvas ROC de los tres modelos, con zoom en la región de bajo FPR (False Positive Rate).

Anexo D: Gráficos complementarios del análisis exploratorio

Este anexo recoge visualizaciones adicionales generadas a lo largo del trabajo, tanto durante el análisis exploratorio de datos (sección 5) como en el análisis de resultados del modelo (sección 10), que complementan la información ya presentada en el cuerpo del informe.



Figura D.1: Distribución de hogares según riesgo de pobreza (vhPobreza).

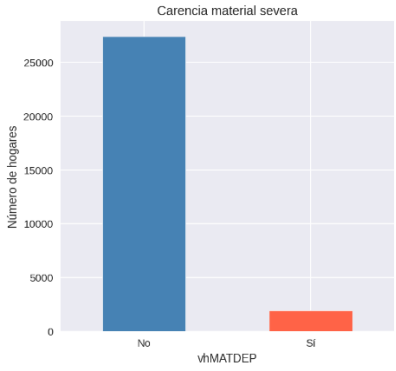


Figura D.2: Distribución de hogares según carencia material severa (vhMATDEP).

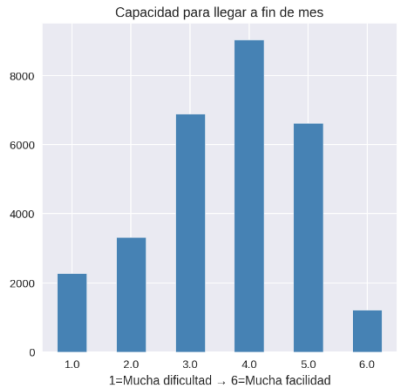


Figura D.3: Distribución de hogares según capacidad para llegar a fin de mes (HS120)

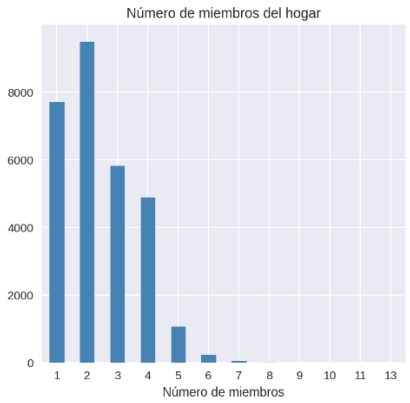


Figura D.4: Distribución del número de miembros del hogar (HB120).

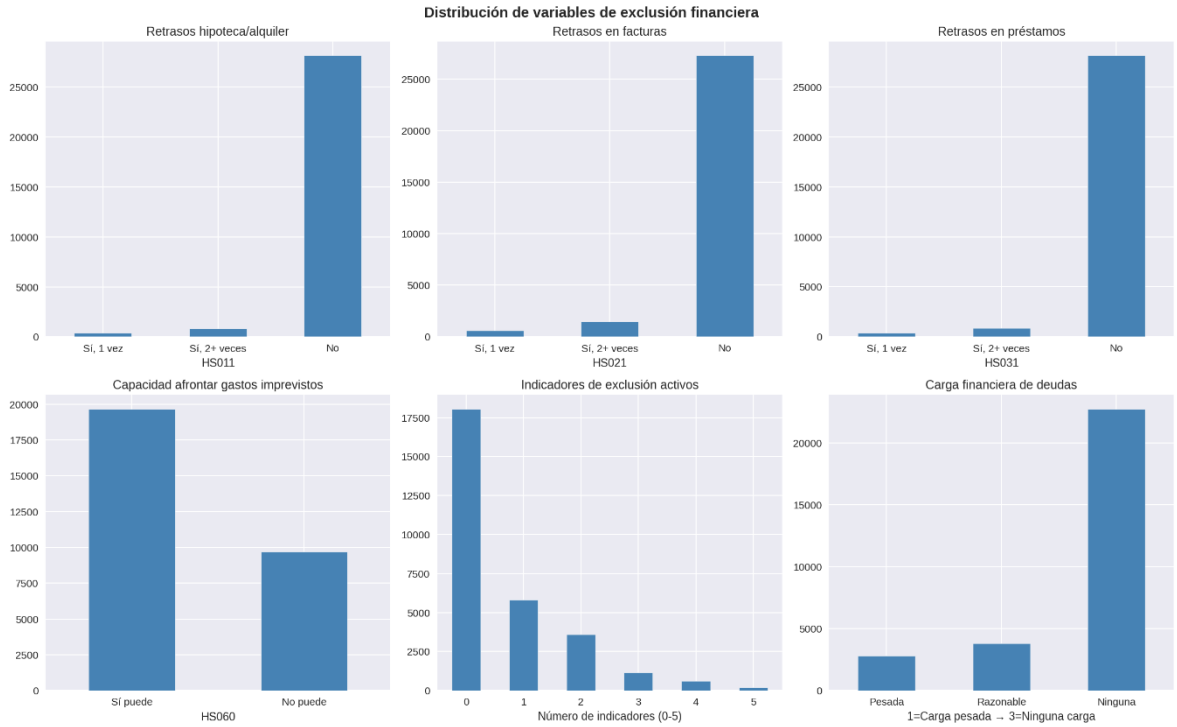


Figura D.5: Distribución de las variables de exclusión financiera (retrasos de pago, capacidad de afrontar imprevistos, indicadores activos y carga de deudas).

VULNERABILIDAD POR COMUNIDAD AUTÓNOMA

CCAA_nombre	n_hogares	n_vulnerables	pct_vulnerables	renta_media	excluidos_media
Melilla	187	47	25.1	41892.0	0.979
Ceuta	209	50	23.9	43923.0	1.019
Andalucía	3206	609	19.0	34048.0	0.915
Extremadura	1079	196	18.2	29895.0	0.754
Murcia	1173	212	18.1	34597.0	0.890
Canarias	1059	187	17.7	35756.0	0.906
Castilla-La Mancha	1200	193	16.1	34954.0	0.753
C. Valenciana	2308	347	15.0	35904.0	0.699
Galicia	1630	197	12.1	36349.0	0.594
Asturias	1051	115	10.9	36445.0	0.570
Castilla y León	1662	170	10.2	36768.0	0.541
Cantabria	853	77	9.0	39335.0	0.540
La Rioja	729	64	8.8	39170.0	0.481
Cataluña	5938	492	8.3	43975.0	0.669
Aragón	1198	87	7.3	41309.0	0.521
Madrid	2861	206	7.2	48243.0	0.602
Navarra	797	49	6.1	46412.0	0.511
Baleares	819	47	5.7	44068.0	0.609
País Vasco	1410	70	5.0	47900.0	0.384

Tabla D.1: Vulnerabilidad, renta media y exclusión financiera media por Comunidad Autónoma (detalle completo de las 19 comunidades).

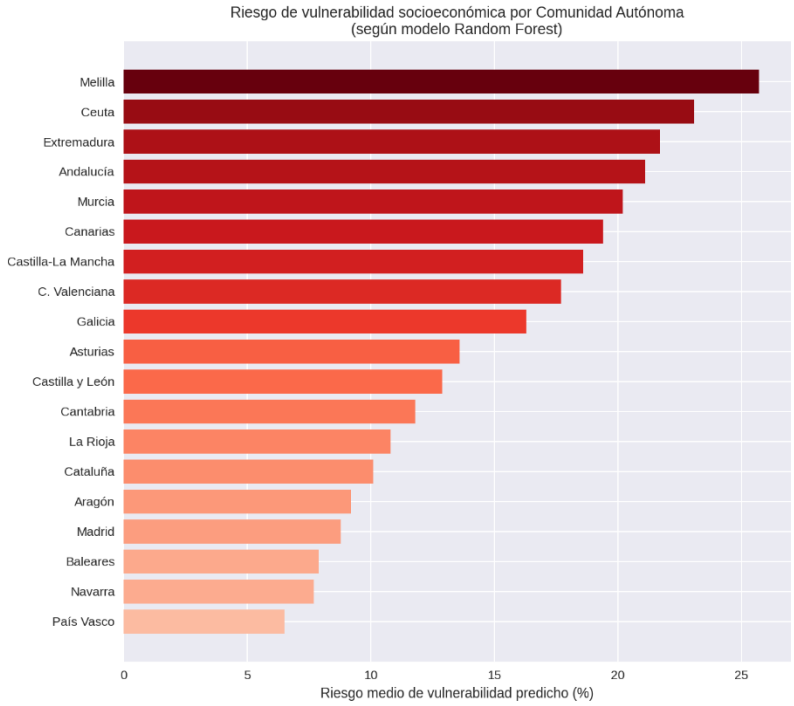


Figura D.6: Riesgo de vulnerabilidad predicho por Comunidad Autónoma (gráfico de barras, complementario al mapa de la Figura 6 del cuerpo del informe, apartado 10).